

Analyse des Technologies d'IA

Application de recommandation de voyages personnalisée

I. Contexte et objectifs du projet

Ce document présente une analyse approfondie des technologies d'IA pertinentes pour la conception d'une plateforme de recommandation de voyages personnalisée. Il a pour objectif de guider les choix d'architecture en tenant compte des contraintes d'un MVP (Minimum Viable Product), des budgets maîtrisés, et d'une évolutivité à long terme.

a) Besoins fonctionnels clés

- Recommandations personnalisées basées sur le profil psychologique (Profil vectoriel personnalisé)
- Prise en compte des interactions sociales : amis, profils similaires
- Intégration de signaux contextuels : météo, événements, actualités locales
- Assistant conversationnel capable d'expliquer et d'affiner les suggestions
- Analyse des tendances (Google trends API, Open Data Tourisme, Données Internes, ...)

b) Contraintes techniques

Contrainte	Détail	Impact sur les choix
Budget	Limité pour le MVP	Privilégier les APIs managées (pay-per-use) afin d'éviter un investissement initial en infrastructure GPU.

Time-to-market	MVP rapide	Éviter les modèles nécessitant fine-tuning, entraînement spécifique ou infrastructure GPU dédiée.
Scalabilité	Croissance progressive	Architecture modulaire, découplage des briques
Conformité RGPD	Données utilisateurs	Anonymisation, pseudonymisation, minimisation des données et séparation des données sensibles.
Explicabilité	Recommandations Compréhensible	Favoriser modèles Interprétables
Maintenance	Équipe réduite	Privilégier des services managés avec SLA et monitoring intégré pour réduire la charge opérationnelle.

II. Collecte et ingestion des données sociales

L'analyse des tendances dans le cadre du MVP repose exclusivement sur des sources open data et des données agrégées, garantissant conformité juridique, stabilité d'accès et maîtrise des coûts. Aucune stratégie de scraping n'est envisagée pour la première version.

a) Sources de données pour l'analyse des tendances MVP

Plateforme	API disponible ?	Accès gratuit	Usage dans Triply
Google trends	Pytrends / Google trends	Gratuit	Identification des destinations en hausse

Open Data Tourisme	DataTourisme API	Gratuit	Lieux, activités, POI officiels
Données Internes	Base triply	Gratuit	Popularité basée sur clics et favoris

Risque juridique — Scraping

Le scraping sans autorisation explicite viole les CGU de la plupart des plateformes et peut constituer une infraction. Le scraping peut être envisagé ultérieurement via des partenariats ou des outils tiers certifiés (Apify, Bright Data).

b) Pipeline d'ingestion recommandé

- Étape 1 — Collecte : Requêtes planifiées vers Google Trends et synchronisation régulière des données Open Data Tourisme
- Étape 2 — Normalisation : Transformation des données en schéma unifié (destination, catégorie, score de popularité normalisé)
- Étape 3 — Stockage : Enregistrement en base PostgreSQL avec indexation par région, catégorie et période
- Étape 4 — Signaux : Calcul d'un TrendScore pondéré combinant tendances Google et popularité interne

c) Données contextuelles complémentaires

Source	API	Données fournies	Gratuité
Météo	Open-Meteo	Prévisions 16j, données historiques	100% gratuit
Événements	Ticketmaster API / Eventbrite	Concerts, festivals, événements locaux	Gratuit (quota limité - clé api requise) /(5000req/jour)
Actualités	NewsAPI.org	Articles de presse par mot-clé et pays	Gratuit quota limité extension payante possible (100 req/jour)

Lieux / POI	Foursquare Places API	Points d'intérêt, restaurants, activités	10,000 req gratuite (free tiers limité, conditions susceptible d'évolution)
-------------	--------------------------	---	---

III. Moteur de recommandation

Le moteur de recommandation constitue la brique centrale de Triply. Pour le MVP, l'objectif n'est pas de construire un système complexe, mais un moteur : pertinent dès l'inscription, simple à maintenir et évolutif, etc.

a) Stratégie de gestion du cold start

Problème du cold start

Le principal défi initial est le cold start : recommander sans historique utilisateur.

Phase 1 — Démarrage (0 à 5 interactions)

- S'appuyer exclusivement sur le profil psychologique (Profil vectoriel personnalisé)
- Calcul de similarité cosine entre profil utilisateur et destination
- Utilisation des préférences déclarées (budget, durée, type de voyage, etc.)
- Recommandations basées uniquement sur la similarité de contenu (content-based filtering)

Phase 2 — Enrichissement (5 à 20 interactions)

- Intégration progressive des feedbacks implicites (clics, temps passé, ajouts en favoris)
- Pondération croissante du comportement réel
- Activation partielle du filtrage collaboratif avec les profils similaires

Phase 3 — Personnalisation complète (20+ interactions)

- Introduction du filtrage collaboratif
- Similarité entre utilisateurs
- Diversification intelligente des recommandations

b) Architecture hybride du moteur

Composant	Technique	Poids MVP	Librairie / Outil
Profil utilisateur	Vecteur simplifié (préférence + profil psychologique)	Fort	numpy
Content-based	Similarité cosine	Fort	scikit-learn, numpy
Collaboratif	Similarité	MVP simplifié	Similarité cosine
Contextuel	Boost pondéré selon météo, events, tendances	Moyen	Règles pondérées custom
Diversification	MMR (Maximal Marginal Relevance)	Faible	Custom

c) Représentation vectorielle du profil utilisateur

Le profil utilisateur est représenté sous forme d'un vecteur de caractéristiques combinant :

- Préférences de voyage : budget, durée, type de voyage
- Axes de personnalités : profil psychologique (Profil vectoriel personnalisé)
- Feedback (clics, favoris, interactions)

Ces valeurs sont indicatives et seront ajustées empiriquement lors des premières itérations.

d) Métriques d'évaluation du moteur

Sans métriques définies dès le départ, impossible de savoir si le moteur s'améliore. Voici les KPIs à instrumenter dès le MVP :

Métrique	Définition	Objectif MVP	Comment mesurer
CTR (Click-Through Rate)	% de recommandations cliquées	À observer et améliorer progressivement	Tracking des interactions UI
Precision @k	Pertinence sur les K premières recommandations affichées	À monitorer via feedback utilisateur	Like, dislike, ajouter en favoris
Diversité	Variété des destinations suggérées	Eviter la répétition excessive	Analyse de distribution des catégories
Satisfaction	Note globale après interaction du voyage	Suivi qualitatif	Enquête post-voyage in-app
Cold start drop-off	% d'abandon lors de la création du compte	Identifier les points de friction	Analytics d'entonnoir (funnel analytics)

IV. Assistant conversationnel — Chatbot IA

Le chatbot est l'interface principale entre l'utilisateur et le moteur de recommandation. Son rôle va au-delà de la simple conversation : il collecte des préférences, explique les suggestions, gère les objections et accompagne tout le parcours utilisateur.

a) Stratégie LLM retenue pour le MVP

Dans le cadre d'un MVP à périmètre restreint, la priorité est de minimiser les coûts tout en gardant le contrôle total sur les données. La stratégie retenue

repose sur des modèles open-source légers, exploitables localement en développement et via des APIs gratuites en production initiale.

b) Comparatif des modèles LLM

Modèle	Via	Contexte	Coût MVP	Qualité	Recommandation
Mistral 7B	Ollama (local)	32k tokens	0€	Bon	Choix MVP
LLaMA 3.2 3B	Ollama (local)	128k tokens	0€	Correct	Option très légère
LLaMA 3.1 8B	Ollama (local)	128k tokens	0€	Bon	Bon équilibre

c) Architecture RAG — Détail technique

L'architecture RAG (Retrieval Augmented Generation) permet d'injecter des données contextuelles dans chaque requête LLM sans fine-tuning. C'est le choix optimal pour un MVP : rapide à implémenter, maîtrisé juridiquement, et évolutif.

Flux RAG — Étapes détaillées

1. Requête utilisateur reçue par le chatbot
2. Extraction des entités clés (destination, dates, budget, activités souhaitées)
3. Requête vectorielle dans pgvector → top 5 destinations pertinentes
4. Récupération du profil utilisateur (pseudonymisé) + contexte (météo, événements)
5. Construction du prompt augmenté : [System prompt] + [Données contextuelles] + [Historique conversation] + [Requête utilisateur]
6. Appel du modèle LLM Local (Ollama) → génération de réponse

d) Gestion du contexte conversationnel

- Fenêtre de contexte : conserver les 10 derniers échanges pour maintenir la cohérence
- Résumé de session : après 10 échanges, compresser l'historique via le LLM Local (Ollama) pour économiser les tokens
- Mémoire persistante : stocker en base les préférences extraites de la conversation (ex: 'préfère la mer à la montagne')
- Gestion des intentions : classifier les messages (demande de reco, question pratique, feedback, hors-sujet)

V. Feuille de route technique — Priorisation MVP

Sur la base de cette analyse, voici la priorisation recommandée pour construire le MVP en 3 phases :

Phase	Durée	Briques à construire	Objectif
Phase 1 — Fondations	Semaines 1-4	Profil psychologique (Profil vectoriel personnalisé) + Content-based filtering + Chatbot LLM Local (Ollama) basique (sans RAG)	Valider l'UX et la pertinence des recommandations initiales
Phase 2 — Enrichissement	Semaines 5-8	Architecture RAG + Collecte APIs météo/événements + Signaux contextuels	Recommandations contextualisées et chatbot intelligent
Phase 3 — Social & Tendances	Semaines 9-12	Amélioration du ranking + métriques + amélioration continue	Personnalisation sociale et optimisation continue

VI. Conformité RGPD et sécurité des données

a) Données sensibles identifiées

Donnée	Sensibilité	Traitement recommandé
Profil psychologique (Profil vectoriel personnalisé)	Donnée de personnalité	Stockée en base, jamais envoyée brute au LLM Local (Ollama)
Historique de navigation	Comportemental	Pseudonymisation (UUID interne), Durée de vie 90 jours
Données sociales collectées	Publiques agrégées	Agrégation par thème, aucun ID utilisateur stocké
Conversations chatbot	Contenu potentiellement sensible	Pseudonymisation, pas de logging des données personnelles,
Localisation	Donnée sensible RGPD	Collecte avec consentement explicite, granularité ville uniquement

6.2 Mesures techniques obligatoires

- Chiffrement au repos et en transit pour toutes les données utilisateurs
- Pseudonymisation systématique avant injection dans le LLM : remplacer noms/emails par des UUID
- Droit à l'effacement : pipeline de suppression complète des données utilisateur sur demande
- Registre de traitement documenté dès le lancement

VII. Synthèse et décisions techniques

Sur la base de cette analyse, voici les décisions techniques retenues pour le MVP :

Brique	Décision retenue	Justification
LLM	Mistral 7B via Ollama (local)	Coût nul, exécution locale, contrôle total des données, conformité RGPD, cohérent avec les contraintes MVP (budget, équipe réduite).
Architecture chatbot	RAG	Données sous contrôle, contexte dynamique, pas de fine-tuning
Recommandation	Hybride content-based + collaboratif	Gestion du cold start via profil psychologique (Profil vectoriel personnalisé) , enrichissement progressif
Données contextuelles	Open-Meteo + Google Trends	Gratuites ou très peu coûteuses, fiables