

BUDGET

Spécifications matérielles et prévisions budgétaires

Ce document détaille les ressources nécessaires pour supporter l'architecture en microservices retenue, en distinguant la phase de lancement (MVP) de la phase de déploiement complet à grande échelle.

I. Phase MVP

L'objectif est d'héberger l'intégralité de la stack (microservices et IA locale) sur une infrastructure unique mais robuste pour minimiser les coûts initiaux.

1. Besoins matériels

- **Instance Serveur (VPS)** : 8 vCPU / 32 Go RAM (Type Hetzner CPX41 ou équivalent Scaleway)
- **Orchestration** : Docker Compose pour isoler les services
- **Stockage IA** : Espace disque SSD (50 Go+) pour le modèle Mistral 7B et la base vectorielle Qdrant
- **Bases de données** : auto-hébergées en conteneurs (PostgreSQL, MongoDB, Redis)

2. Budget mensuel estimatif

Poste	Détail	Coût HT
Hébergement VPS	Serveur 32 Go RAM (incluant CPU/Stockage)	45€
LLM (Chatbot)	Mistral 7B via Ollama (Exécution locale)	0€

Bases de données	Auto-hébergement (Postgres, Mongo, Redis, Qdrant)	0€
Services Carto	Mapbox (Gratuit jusqu'à 25 000 chargements)	0€
APIs Météo/Trends	Open-Meteo et Google Trends (Versions gratuites)	0€
Total Mensuel		45€

Note : Frais de mise en service (Stores) : 99€/an (Apple) + 25€ à vie (Google).

II. Phase V1.1

L'objectif est d'enrichir l'application avec des alertes géo/météo, l'analyse des tendances sociales et un chatbot amélioré. La stratégie "Open-Source First" est maintenue pour préserver la légèreté financière de l'infrastructure. Le budget reste inchangé.

1. Besoins matériels

- **Instance serveur (VPS)** : 8 vCPU / 32 Go RAM (conservation du même serveur que pour la phase MVP)
- **Orchestration** : Docker Compose pour isoler les services
- **Stockage IA** : Espace disque SSD (50 Go+) pour le modèle Mistral 7B et la base vectorielle Qdrant
- **Bases de données** : auto-hébergées en conteneurs (PostgreSQL, MongoDB, Redis)

2. Budget mensuel estimatif

Poste	Détail	Coût HT

Hébergement VPS	Serveur 32 Go RAM (incluant CPU/Stockage)	45€
LLM (Chatbot)	Mistral 7B via Ollama (Exécution locale)	0€
Bases de données	Auto-hébergement (Postgres, Mongo, Redis, Qdrant)	0€
Services Carto	Mapbox (Gratuit jusqu'à 25 000 chargements)	0€
APIs Météo/Trends	Open-Meteo et Google Trends (Versions gratuites)	0€
Total Mensuel		45€

III. Phase V1.2

L'objectif est d'intégrer l'aspect communautaire et social de l'application. Cela nécessite une évolution matérielle ciblée, pour permettre le lancement du fil d'actualité communautaire et de la génération de carnets de voyage PDF avec ajout de photos.

1. Besoins matériels

- **Instance serveur (VPS)** : 8 vCPU / 32 Go RAM (conservation du même serveur que pour la phase MVP)
- **Stockage objet (S3)** : hébergement des médias (photos et vidéos) intégrés par les utilisateurs dans leurs carnets de voyage

2. Budget mensuel estimatif :

Poste	Détail	Coût HT
Hébergement VPS	Serveur 32 Go RAM (incluant CPU/Stockage)	45€
LLM (Chatbot)	Mistral 7B via Ollama (Exécution locale)	0€
Bases de données	Auto-hébergement (Postgres, Mongo, Redis, Qdrant)	0€
Services Carto	Mapbox (Gratuit jusqu'à 25 000 chargements)	0€
APIs Météo/Trends	Open-Meteo et Google Trends (Versions gratuites)	0€
Stockage S3	Hébergement des médias (Photos/Vidéos carnets)	50€
Total Mensuel		95€

IV. Phase V2

L'objectif est de passer à une infrastructure distribuée pour supporter le trafic (mis à échelle), les fonctionnalités sociales et la gamification, pour le déploiement de la V2 (application complète).

1. Besoins matériels

- **Calcul (compute)** : Cluster Kubernetes (K8s) pour gérer la scalabilité des microservices

- **IA (LLM)** : abandon du serveur GPU dédié au profit d'API Cloud payées à l'usage (tokens). Le RAG continuera d'alimenter ces modèles avec le contexte de la base vectorielle Qdrant

OU

Possibilité de monter un serveur local pour limiter les frais de tokens (prise en compte de l’augmentation des tarifs depuis juin 2026), avec :

- **carte graphique** type Nvidia RTX 4060 Ti (16 Go)
- **processeur** type AMD Ryzen 5 5600 ou Intel i5-12400
- **RAM** 32 Go DDR4 / DDR5
- **SSD** 1 To NVMe M.2 type Crucial P3 Plus
- **alimentation** 650W ou 750W
- **carte mère** Chipset B550 (AMD) ou B760 (Intel)
- **Boîtier** Moyen Tour bien ventilé + **Ventirad** CPU

→ pour environ 900€

- **Stockage objet** : archivage des photos des carnets de voyage générés par les utilisateurs
- **Bases managées** : migration vers des services DB avec sauvegardes et répliquations automatiques

2. Budget mensuel estimatif

Poste	Option A : APIs Cloud	Option B.1 : IA Locale (avec investissement lissé sur 2 ans)	Option B.2 : IA Locale (avec investissement initial)
Cluster K8s (Cloud)	200€	200€	200€
Bases de données managées	120€	120€	120€

Stockage S3 (Médias)	50€	50€	50€
APIs Premium (Mapbox, etc.)	250€	250€	250€
IA (LLM)	150 à 600€ (selon trafic)	47,5€ (37,5€ amortissement + 10€ électricité)	910€ le 1er mois (achat de la carte graphique), puis ~10€ (électricité)
Total mensuel	770€ à 1200€	667,5€ (fixe) sur 2 ans, puis 630€ (fixe)	1530€ le 1er mois, puis 630€ (fixe)

V. Synthèse des choix d'optimisation budgétaire

1. **Architecture microservices** : permet d'isoler le coût de l'IA (le service le plus cher) et de ne scaler que les briques nécessaires (ex: augmenter la RAM uniquement pour le service social)
2. **Open-Source First** : l'usage d'Ollama (LLM) et de Qdrant (vecteurs) permet d'éviter les frais de tokens pour le MVP
3. **Légèreté au lancement** : le choix de Docker Compose sur un serveur unique pour le MVP permet de démarrer avec un budget initial faible sans sacrifier la structure technique finale
4. **IA sur serveur local (V2)** : permet de ne pas augmenter les coûts si beaucoup de trafic. Cela peut représenter une économie d'environ 7860€ sur 2 ans par rapport à un usage modéré des API cloud (sur une estimation d'utilisation de base des tokens de 375€/mois). Le coût de l'investissement matériel est amorti en 2 à 3 mois.